

Caso de Negocio: Subtes de Buenos Aires

El objetivo de este trabajo final fue preparar, limpiar, transformar y analizar los datos históricos de la demanda de los pasajeros, el cronograma operativo invernal y tarifas del Subte de la Ciudad Autónoma de Buenos Aires durante el período comprendido entre marzo y noviembre de 2018, generando datasets listos en Python para su posterior visualización en Power BI. Se seleccionó este intervalo temporal debido a que coincide con una etapa del año caracterizada por una elevada actividad urbana, en la que una gran cantidad de ciudadanos utiliza este medio de transporte para asistir a sus lugares de trabajo, instituciones educativas y otras actividades cotidianas.

Asimismo, se decidió trabajar con información correspondiente al año 2018 debido a que constituye el último período para el cual se dispone de datos abiertos completos sobre las variables analizadas. Esta decisión permitió mantener la coherencia temporal entre los distintos datasets utilizados, garantizando que todos los indicadores empleados en el trabajo correspondieran al mismo contexto histórico y pudieran ser comparados de manera consistente.

Para el desarrollo del proceso ETL y del análisis exploratorio se utilizaron diversas bibliotecas de Python. En primer lugar, Pandas (`import pandas as pd`), empleada para la manipulación y transformación de datos. En segundo lugar, Matplotlib (`import matplotlib.pyplot as plt`), utilizada para la creación de gráficos. Asimismo, se incorporó Seaborn (`import seaborn as sns`) con el objetivo de generar visualizaciones estadísticas más elaboradas. Por otra parte, se empleó MinMaxScaler (`from sklearn.preprocessing import MinMaxScaler`) para la normalización de variables numéricas y FuncFormatter (`from matplotlib.ticker import FuncFormatter`) para personalizar el formato de los ejes en los gráficos. Con el fin de mantener una estética uniforme a lo largo de todo el análisis, también se configuró un estilo visual común mediante la instrucción `sns.set_theme(style="whitegrid")`.

Posteriormente, se cargaron tres conjuntos de datos. El primero, `historico_2018.csv`, contiene información sobre la demanda de pasajeros por estación y molinete. El segundo, `cronograma-invierno.csv`, reúne los horarios operativos y la planificación de servicios de las distintas líneas de la red. Finalmente, `registro-historico-del-precio-del-boleto.csv` proporciona información histórica sobre las tarifas del servicio.

Una vez cargados los archivos, se realizó una exploración inicial con el propósito de evaluar la calidad de los datos. Durante esta etapa se detectó la presencia de registros

Caso de Negocio: Subtes de Buenos Aires

duplicados, valores nulos, diferencias en los formatos de texto y variables con tipos de datos inconsistentes. Por esta razón, se incorporó una fase específica de limpieza y transformación antes de avanzar con el análisis.

En primer lugar, se verificó la existencia de registros duplicados. Los resultados mostraron que el dataset de demanda contenía 78.203 registros repetidos, mientras que los archivos de cronograma y boleto no presentaban duplicados. Debido a que estos registros podían provocar una sobreestimación de la cantidad de pasajeros y distorsionar tanto las estadísticas descriptivas como las visualizaciones posteriores, se decidió eliminarlos mediante la función `drop_duplicates()`.

A continuación, se llevó a cabo un proceso de normalización de texto sobre diversas variables categóricas. Esta tarea incluyó la conversión de caracteres a minúsculas, la eliminación de espacios en blanco innecesarios y la homogeneización de categorías equivalentes. Estas transformaciones permitieron garantizar la consistencia de los agrupamientos y evitar que una misma categoría fuese interpretada como valores distintos durante los análisis y las visualizaciones.

Posteriormente, se realizó un análisis de valores nulos en los tres conjuntos de datos. En el archivo de demanda se identificaron valores faltantes en la mayoría de sus columnas, incluyendo fecha, desde, hasta, línea, molinete, estación, pasajeros pagos, pases pagos, franquicias y total de pasajeros. Dado que estos campos eran fundamentales para el análisis, se eliminaron los registros con fechas inválidas mediante `dropna(subset=["fecha"])` y aquellos que carecían de información sobre la línea o el total de pasajeros utilizando `dropna(subset=["total", "línea"])`.

Por otro lado, el dataset de cronograma presentaba valores faltantes en las columnas `SAL_C1`, `SAL_C2`, `INT_C1`, `INT_C2`, `FORM` y `OBSERVACIONES`. Inicialmente se evaluaron distintas alternativas para tratar estos registros, como la imputación mediante la media o la mediana. Sin embargo, tras analizar la naturaleza de la información, se concluyó que cada línea opera con frecuencias y horarios particulares. En consecuencia, reemplazar dichos valores podría afectar la calidad del análisis. Por este motivo, se decidió conservar los valores nulos originales. En contraste, el archivo correspondiente al precio del boleto no presentó valores faltantes.

Con el objetivo de facilitar los análisis temporales, la variable fecha fue convertida al formato `datetime` mediante la función `pd.to_datetime()`. Esta transformación permitió filtrar

Caso de Negocio: Subtes de Buenos Aires

períodos específicos, generar nuevas variables temporales y realizar agrupamientos por mes y día de la semana.

Durante el proceso de filtrado temporal se detectó una inconsistencia importante entre los datasets. Mientras que el archivo de demanda se encontraba acotado al período de estudio, los datasets de cronograma y tarifas contenían información correspondiente a varios años. Para asegurar la coherencia del análisis, se decidió filtrar exclusivamente los registros correspondientes a 2018 mediante `cronograma["PERIODO"] == 2018` y `boleto["año"] == 2018`. Asimismo, en el dataset de demanda se conservó únicamente la información comprendida entre el 1 de marzo y el 30 de noviembre de 2018.

Como resultado, el análisis quedó conformado por 3.139 registros operativos y las líneas A, B, C, D, E y Premetro. Cabe destacar que no se encontraron registros correspondientes a la Línea H para el período seleccionado; tras revisar el origen de los datos, se identificó que esta ausencia se debe a una limitación en la carga de la información oficial por parte del GCBA en el dataset de cronogramas para ese año. En consecuencia, dicha línea fue excluida de este apartado para garantizar que todas las comparaciones y visualizaciones se realizaran sobre un mismo marco temporal y consistente.

Con el propósito de enriquecer el análisis temporal, se generaron nuevas variables a partir de la columna fecha: el mes y el día de la semana. Inicialmente, los nombres de los días eran generados automáticamente en inglés. Dado que el informe y las visualizaciones estaban orientados a un contexto hispanohablante, se realizó una traducción de estas categorías al español (Lunes, Martes, etc.). Esta transformación mejoró la legibilidad de los gráficos. Posteriormente, durante la construcción de las visualizaciones, se detectó que los días de la semana aparecían ordenados alfabéticamente en lugar de seguir su secuencia cronológica natural. Como consecuencia, se definió manualmente un orden específico para garantizar una correcta representación temporal y evitar interpretaciones erróneas.

En cuanto a la limpieza numérica, la variable total fue convertida a formato numérico mediante `pd.to_numeric()`. Después, se eliminaron aquellos registros que presentaban valores nulos, iguales a cero o negativos, ya que no representaban una demanda válida de pasajeros.

Una vez completadas las etapas de limpieza, se procedió a la detección de valores atípicos mediante el método del rango intercuartílico (IQR). Los resultados mostraron la existencia de 446.280 registros considerados outliers, equivalentes al 4,98% del total de observaciones. A pesar de ello, se decidió no eliminar estos valores extremos. Tras una

Caso de Negocio: Subtes de Buenos Aires

revisión detallada se comprobó que correspondían principalmente a las estaciones de mayor afluencia en horas pico, donde se registraron picos de hasta 464 pasajeros por registro de molinete. En consecuencia, se interpretó que dichos valores no constituían errores de medición, sino picos reales de demanda que forman parte del comportamiento habitual del sistema de transporte y, por lo tanto, debían conservarse. Con el propósito de complementar este análisis, se incorporó un boxplot que permitió visualizar gráficamente la distribución de la demanda y confirmar la presencia de estos outliers.


Además, se realizó un proceso de normalización sobre la variable total mediante la técnica Min-Max Scaling (`MinMaxScaler()`). Como resultado, se generó la variable `total_normalizado` (con valores entre 0 y 1). Si bien este procedimiento se incorporó inicialmente como un requerimiento metodológico, su análisis resultó sumamente valioso: mostró una media de 0.064 y evidenció que el 77.97% de los registros se concentraba en el intervalo entre 0 y 0.1. Este comportamiento confirmó matemáticamente la fuerte concentración de observaciones en niveles bajos y moderados de demanda, dejando los valores más elevados como fenómenos específicos de las horas pico.

Como parte del análisis exploratorio, se calcularon medidas de tendencia central y dispersión sobre los datos reales, obteniéndose una media de 30.83 millones de pasajeros, una mediana de 21 millones de pasajeros y una desviación estándar de 31.96 millones de pasajeros. La diferencia entre la media y la mediana sugiere una distribución asimétrica influenciada por los registros de demanda elevada. Asimismo, se calculó el total de pasajeros transportados durante el período analizado, alcanzando aproximadamente 276.1 millones de viajes, lo que permite dimensionar la magnitud de la red estudiada.

Una vez finalizadas las etapas de preparación, se procedió a la construcción de diversas visualizaciones en Python:


Caso de Negocio: Subtes de Buenos Aires

Evolución mensual de la demanda:



Un gráfico de líneas que reflejó un máximo de 33.3 millones de pasajeros en Agosto, seguido por una disminución en septiembre (29.3 millones) y noviembre (29.2 millones), permitiendo identificar tendencias temporales y posibles comportamientos estacionales.


1. Distribución de la demanda según el día:



Se evidenció, en un gráfico de barra, una fuerte concentración de viajes durante los días hábiles, destacándose el jueves con 52.6 millones de pasajeros y el miércoles con 50.6 millones. En contraste, el domingo presentó una reducción considerable, con solo 10.7 millones de pasajeros.


Caso de Negocio: Subtes de Buenos Aires

2. Distribución de pasajeros por línea:



Se observó, en otro gráfico de barras, que las líneas B y D registran los mayores volúmenes de demanda (72.5 y 65.8 millones respectivamente), mientras que la línea E presenta valores considerablemente inferiores, cercanos a los 18.5 millones.


3. Las 10 estaciones con mayor demanda:



El tercer gráfico de barras identificó que Constitución concentra aproximadamente 20.4 millones de usuarios, seguida por Retiro con 9.6 millones. La importancia de este hallazgo radica en que ambas estaciones funcionan como nodos de trasbordo intermodal clave, conectando el subte con las principales terminales ferroviarias.

Caso de Negocio: Subtes de Buenos Aires


4. Cantidad de coches utilizados por línea según el día:



Se incorporó una matriz de calor para analizar la oferta de servicios programados, reemplazando las categorías originales por "Lunes a Viernes", "Sábado" y "Domingo". La visualización cruzó las líneas con los tipos de día, permitiendo observar la cantidad de coches para cada línea según el tipo de día. Esto facilitó la comparación entre la oferta disponible y la demanda real.

Caso de Negocio: Subtes de Buenos Aires

5. Correlación entre tarifa y demanda:



Se integraron los datasets independientes mediante la función `merge()` para desarrollar un gráfico de dispersión con línea de tendencia e intervalo de confianza. El coeficiente de correlación obtenido fue de 0.210. Este resultado indica una relación débil, es decir, a pesar de los aumentos escalonados en el precio del boleto ocurridos durante 2018, los aumentos tarifarios no parecen haber tenido un impacto significativo sobre la cantidad de pasajeros transportados. Sin embargo, serían necesarios estudios adicionales para determinar con mayor precisión el grado de elasticidad de la demanda.

Una vez completado el análisis en Python, se exportaron tres datasets finales: `demanda_2018_limpia.csv`, `cronograma_limpio.csv` y `boleto_limpio.csv`. Esta decisión permitió separar claramente las etapas de procesamiento y visualización, evitando repetir tareas de limpieza dentro de Power BI y garantizando que todas las visualizaciones se construyeran a partir de información previamente depurada y validada.

Los archivos fueron importados en Power BI, donde se construyó el modelo de datos estableciendo una relación de varios a uno (*:1) entre la variable Mes del dataset `boleto_limpio` y la variable MesNombre del dataset `demanda_2018_limpia`. Esta relación permitió integrar la información tarifaria con los datos de demanda y garantizar la correcta

Caso de Negocio: Subtes de Buenos Aires

interacción entre las visualizaciones y los filtros temporales. Asimismo, se revisaron y ajustaron los tipos de datos asignados automáticamente por la herramienta (configurando las fechas como tipo Fecha, la cantidad de pasajeros como número entero, el precio del boleto como número decimal y las variables categóricas como texto) para asegurar el correcto funcionamiento de las medidas DAX, mediante las cuales se replicaron los indicadores clave (total de pasajeros, media, mediana y desviación estándar).

Durante esta etapa, se realizaron ajustes adicionales de calidad sobre diversas categorías, estandarizando nombres y formatos para mejorar la consistencia visual de los gráficos, y se corrigieron valores que aparecían concatenados o con formatos poco legibles para favorecer una mejor interpretación. Asimismo, se detectaron algunos valores faltantes en variables operativas; sin embargo, dado que dichos registros no afectaban los análisis principales, se decidió conservarlos para evitar la pérdida innecesaria de información.

Durante el proceso de diseño del dashboard, se utilizaron columnas auxiliares de ordenamiento para resolver las jerarquías automáticas de fechas que Power BI desordenaba alfabéticamente. Las páginas fueron estructuradas por temática, siguiendo una lectura natural de izquierda a derecha e incorporando botones interactivos para la navegación secuencial.

Desde el punto de vista estético, tanto en Python como en Power BI se adoptó la paleta de colores característica del Gobierno de la Ciudad Autónoma de Buenos Aires, utilizando el amarillo institucional como color predominante con el fin de reforzar la identidad visual del proyecto. En el caso de Python, para el mapa de calor se optó por la paleta YlGnBu, ya que el azul oscuro de los valores más altos se asemeja al azul institucional utilizado por el Gobierno de la Ciudad. Además, esta combinación transmite una estética moderna asociada al transporte, la movilidad y el análisis de datos, y ofrece una adecuada visualización de las diferencias de intensidad entre los valores. Por otra parte, en el gráfico de dispersión, tanto en Python como en Power BI, se representó cada mes mediante un color diferente, lo que facilita la identificación y comparación de los datos correspondientes a cada período. En el caso de Python, además, se incorporó un fondo gris, recurso visual que no pudo replicarse en Power BI debido a las opciones de personalización disponibles en dicha herramienta. La utilización de este fondo permitió resaltar tanto los puntos correspondientes a cada mes como la línea de tendencia y su intervalo de confianza, facilitando la interpretación de la relación entre el precio del boleto y la demanda de pasajeros. Asimismo, el sombreado gris que rodea a la línea de tendencia representa el intervalo de confianza del ajuste lineal.

Caso de Negocio: Subtes de Buenos Aires

Esta banda muestra el rango dentro del cual es probable que se encuentren los valores reales de la relación entre ambas variables, reflejando el grado de incertidumbre asociado a la estimación. Cuanto más amplia es esta zona, mayor es la variabilidad de los datos y, por lo tanto, menor la precisión del modelo de ajuste. Finalmente, luego de elaborar las visualizaciones en ambos programas, se observó que en Python algunos valores se presentan redondeados para mejorar la legibilidad de los gráficos, mientras que en Power BI es posible visualizar el valor exacto de cada dato al posicionar el cursor sobre la visualización.

Conclusiones:

El análisis de la demanda del Subte de la Ciudad Autónoma de Buenos Aires durante el período comprendido entre marzo y noviembre de 2018 permitió identificar una marcada concentración de pasajeros durante los días hábiles, especialmente los miércoles y jueves, mientras que los fines de semana registraron niveles considerablemente menores de utilización. A nivel mensual, Agosto presentó el mayor volumen de pasajeros, evidenciando variaciones temporales relevantes a lo largo del período analizado.

Asimismo, las estaciones Constitución y Retiro se consolidaron como los principales nodos de transferencia de la red, y las líneas B y D concentraron los mayores volúmenes de pasajeros, en contraste con la línea E, que registró una demanda significativamente inferior. Los valores atípicos detectados fueron validados como eventos reales asociados a estaciones de alta afluencia y no como errores de captura. Finalmente, el análisis de correlación evidenció una relación débil entre el precio del boleto y la cantidad de pasajeros transportados.

En conjunto, los resultados obtenidos permitieron caracterizar los patrones de uso de la red de subterráneos y demostrar la utilidad de las herramientas de análisis de datos y visualización empleadas, generando información relevante para la comprensión del comportamiento de la demanda.

Recomendaciones:

Incrementar la frecuencia y la capacidad de transporte en las líneas B y D durante los días hábiles, con especial énfasis en los miércoles y jueves, con el fin de responder de manera más eficiente a los picos de demanda identificados.

Reforzar los planes de mantenimiento, señalización y seguridad en las estaciones Constitución y Retiro, debido a que se consolidan como los principales nodos de transferencia de la red.

Caso de Negocio: Subtes de Buenos Aires

Implementar estrategias orientadas a mejorar la circulación de pasajeros y reducir la saturación en las estaciones de mayor afluencia, contribuyendo a una mejor experiencia de viaje.

Realizar estudios complementarios sobre la línea E para identificar las posibles causas de su menor utilización y evaluar oportunidades de mejora en términos de conectividad, frecuencia y calidad del servicio.

Considerar que la relación observada entre el precio del boleto y la cantidad de pasajeros transportados es débil. En consecuencia, las modificaciones tarifarias deberían acompañarse con mejoras en la calidad, regularidad y confort del servicio.

Continuar utilizando herramientas de análisis y visualización de datos para monitorear los patrones de movilidad y facilitar la toma de decisiones operativas y estratégicas basadas en evidencia.

Incorporar información correspondiente a otros períodos y variables adicionales para profundizar el estudio del comportamiento de los usuarios y detectar nuevas tendencias de demanda.

Aprendizajes del trabajo final:

El desarrollo del proyecto permitió aplicar de manera integral técnicas de limpieza, transformación, exploración y visualización de datos utilizando Python y Power BI. Durante el proceso se evidenció la importancia de realizar una adecuada preparación de los datos antes de iniciar cualquier análisis, ya que los problemas de calidad o las inconsistencias temporales de las fuentes públicas pueden distorsionar significativamente los resultados. Asimismo, se comprobó que la combinación de Python para el procesamiento pesado de datos y Power BI para la construcción de dashboards interactivos constituye una estrategia eficiente para transformar grandes volúmenes de información en conocimiento útil para la toma de decisiones. Finalmente, el proyecto cumplió con el objetivo de identificar los patrones clave de movilidad de la red de subterráneos y reforzó los conocimientos vinculados al análisis exploratorio de datos y la comunicación visual de resultados.

Storytelling

Hola, mi nombre es Mercedes Milagros Alcorta. Soy Licenciada en Ciencia Política y Magíster en Derechos Humanos y Democratización para América Latina y el Caribe. Como desafío profesional para obtener la certificación de Data Analyst de Digital House, analicé los datos del período de marzo a noviembre del 2018 del Subte de la Ciudad de Buenos Aires.

Caso de Negocio: Subtes de Buenos Aires

Durante la navegación por el dashboard, el usuario podrá cambiar de página seleccionando la flecha ubicada en la parte inferior de la pantalla.

En la primera página podemos observar un gráfico de línea sobre la evolución mensual de la demanda. A su costado se encuentra el total de pasajeros, la media, la mediana y la desviación estándar. Como resultado, hubo un total de 276 millones de pasajeros y Agosto fue el mes con mayor demanda. En esta sección es posible seleccionar distintos meses y, al mismo tiempo, visualizar las medidas estadísticas y la cantidad total de pasajeros correspondiente a cada uno de ellos.

En la segunda página podemos ver tres gráficos de barra. En la primera analicé cómo se distribuye la demanda según el día. Se puede ver que los días hábiles concentran la mayor cantidad de pasajeros, especialmente los miércoles y jueves, mientras que los fines de semana presentan una demanda considerablemente menor. En el segundo gráfico, podemos observar que las líneas B y D son las que transportan más pasajeros, y en el tercer gráfico que las estaciones de Constitución y Retiro son las más utilizadas. Esto puede deberse a que son puntos de conexión con terminales de tren. Al seleccionar una categoría, las demás visualizaciones se ajustan en función a la elección realizada. De esta manera, los datos vinculados a la selección se muestran resaltados, lo que facilita su comparación e interpretación.

En la tercera página podemos ver la cantidad de coches utilizados por cada línea según el día. La matriz permite observar diferencias entre los días hábiles y los fines de semana. También se puede ver la relación entre el precio del boleto y la cantidad de pasajeros. El análisis mostró una relación débil, lo que indica que las variaciones en la tarifa no explican por sí solas los cambios en la demanda.

En cuanto al diseño del dashboard, la mayoría de las visualizaciones son amarillas para otorgarle un carácter institucional, tomando como referencia el color característico del Gobierno de la Ciudad de Buenos Aires. La excepción es el gráfico de dispersión, donde cada mes se representa con un color diferente, lo que permite al usuario identificar y comparar los datos de una manera más sencilla.

Este trabajo permitió identificar distintos patrones de movilidad y obtener información útil para la planificación del servicio. A partir de los resultados obtenidos, se pueden plantear algunas recomendaciones. Por ejemplo, dado que las líneas B y D son las que concentran la mayor cantidad de pasajeros, sería conveniente reforzar su capacidad y

Caso de Negocio: Subtes de Buenos Aires

frecuencia durante los días de mayor demanda para evitar colapsos. Las estaciones de Constitución y Retiro, al ser las más utilizadas, se podrían priorizar en ellas las tareas de mantenimiento, seguridad y circulación de pasajeros. También sería interesante profundizar el estudio de la línea E para comprender cuáles son las causas de su menor utilización y evaluar posibles mejoras en el servicio. Por otra parte, como el análisis mostró una relación débil entre el precio del boleto y la cantidad de pasajeros transportados, las políticas tarifarias deberían complementarse con acciones orientadas a mejorar la calidad del viaje.

Este trabajo demuestra la importancia de seguir utilizando herramientas de análisis y visualización de datos, porque permiten obtener información valiosa para apoyar la toma de decisiones y contribuir a una planificación más eficiente del sistema de transporte.